

THÔNG TIN CHUNG CỦA NHÓM

- Link YouTube video của báo cáo (tối đa 5 phút):
<https://youtu.be/iOvACe4b7a0>
- Link slides (dạng .pdf đặt trên Github của nhóm):
<https://github.com/namnh-tt/CS2205.JAN2026/blob/3dc0df18b2600f49272fcb145586ce1a04a03c7a/Nam%20Nguy%E1%BB%85n%20Ho%C3%A0ng%20-%20CS2205.JAN2026.DeCuong.FinalReport.Template.Slide.pdf>
- *Mỗi thành viên của nhóm điền thông tin vào một dòng theo mẫu bên dưới*
- *Sau đó điền vào Đề cương nghiên cứu (tối đa 5 trang), rồi chọn Turn in*
- *Lớp Cao học, mỗi nhóm một thành viên*

- Họ và Tên: Nguyễn Hoàng
Nam
- MSSV: 250106023



- Lớp: CS2205.JAN2026
- Tự đánh giá (điểm tổng kết môn): 9/10
- Số buổi vắng: 0
- Số câu hỏi QT cá nhân: 4
- Link Github:
<https://github.com/namnh-tt/CS2205.JAN2026>
- Link Youtube:
<https://youtu.be/iOvACe4b7a0>

ĐỀ CƯƠNG NGHIÊN CỨU

TÊN ĐỀ TÀI (IN HOA)

MỘT PHƯƠNG PHÁP HỌC LIÊN KẾT THÍCH NGHI DỰA TRÊN JSD VÀ CÁ NHÂN HÓA MÔ HÌNH CHO DỮ LIỆU WIFI CSI KHÔNG ĐỒNG NHẤT

TÊN ĐỀ TÀI TIẾNG ANH (IN HOA)

A JSD-GUIDED PERSONALIZED FEDERATED LEARNING APPROACH FOR NON-IID WIFI CSI DATA

TÓM TẮT (Tối đa 400 từ)

Nhận diện sự hiện diện của con người dựa trên thông tin trạng thái kênh WiFi (WiFi Channel State Information – CSI) là một hướng nghiên cứu tiềm năng trong các hệ thống nhà thông minh, quản lý năng lượng và giám sát an ninh nhờ khả năng bảo vệ quyền riêng tư tốt hơn so với các giải pháp sử dụng camera. Khi triển khai trên nhiều thiết bị ESP32 tại các môi trường khác nhau, Federated Learning (FL) cho phép huấn luyện mô hình chung mà không cần tập trung dữ liệu CSI về máy chủ.

Tuy nhiên, sự khác biệt về diện tích phòng, vật cản và bố trí nội thất làm cho dữ liệu CSI giữa các thiết bị có phân phối không đồng nhất (Non-IID). Hiện tượng này gây ra client drift và làm giảm hiệu quả của các thuật toán FL truyền thống như FedAvg và FedProx. Một số phương pháp gần đây như FedAPA khai thác độ tương đồng giữa các client thông qua prototype trong không gian embedding, nhưng yêu cầu chi phí tính toán tương đối cao đối với các thiết bị nhúng tài nguyên hạn chế.

Để giải quyết vấn đề trên, đề tài đề xuất FedJPA (Federated Learning with JSD-guided Personalized Aggregation). Phương pháp gồm hai thành phần chính: (i) cơ chế tổng hợp có trọng số dựa trên Jensen–Shannon Divergence (JSD) sử dụng histogram biên độ CSI để đánh giá mức độ tương đồng giữa các client; và (ii) cơ chế cá nhân hóa mô hình, trong đó các lớp dùng chung được tổng hợp toàn cục, còn lớp cá nhân hóa được giữ lại trên từng thiết bị để thích nghi với môi trường cục bộ.

Hệ thống dự kiến được đánh giá trên 3–5 thiết bị ESP32-S3 tại nhiều môi trường khác nhau. Kết quả kỳ vọng cho thấy FedJPA đạt độ chính xác trên 92%, F1-Score trên 88%, hội tụ trong không quá 40 vòng giao tiếp và cải thiện hiệu năng so với FedAvg, FedProx và FedNova trong điều kiện dữ liệu CSI Non-IID thực tế.

GIỚI THIỆU (Tối đa 1 trang A4)

1. Bài toán và bối cảnh:

Nhận diện sự hiện diện của con người là nền tảng cho nhiều ứng dụng nhà thông minh, an ninh và quản lý năng lượng. So với camera, phương pháp sử dụng thông tin trạng thái kênh WiFi (Channel State Information – CSI) có ưu điểm bảo vệ quyền riêng tư vì không thu thập hình ảnh. Khi triển khai trên các thiết bị ESP32 phân tán, việc tập trung dữ liệu CSI về máy chủ gặp hạn chế về băng thông, độ trễ và bảo mật. Federated Learning (FL) cho phép huấn luyện mô hình mà không cần chia sẻ dữ liệu thô, chỉ trao đổi tham số mô hình. Tuy nhiên, do sự khác biệt về môi trường triển khai (diện tích phòng, vật cản, bố trí nội thất), dữ liệu CSI giữa các thiết bị thường có phân phối khác nhau (Non-IID). Hiện tượng này làm giảm độ chính xác và tốc độ hội tụ của các thuật toán FL truyền thống như FedAvg [1].

2. Khoảng trống nghiên cứu

Dù các phương pháp FL giải quyết Non-IID đã được đề xuất [2][3][4], chúng chủ yếu thử nghiệm trên benchmark ảnh nhân tạo (MNIST, CIFAR-10) qua phân phối Dirichlet mô phỏng. Trong lĩnh vực WiFi CSI, tính Non-IID xuất hiện tự nhiên từ môi trường thực tế nhưng chưa được định lượng hệ thống. Đồng thời, các nghiên cứu FL ứng dụng dữ liệu CSI trên nền tảng nhúng hạn chế tài nguyên như ESP32 còn rất hạn chế, tạo ra khoảng trống lớn về cả lý thuyết lẫn thực nghiệm triển khai.

3. Input và Output của nghiên cứu

Input: Dữ liệu WiFi CSI thu thập từ 3–5 thiết bị ESP32 ở các môi trường khác nhau, nhãn nhị phân (có người/không có người), thông tin số lượng mẫu và phân phối đặc trưng tại mỗi node.

Output: Mô hình gồm shared layers θ_*^S (toàn cục) và personal layers θ_{i*}^P (tại mỗi ESP32) đạt $\text{Accuracy} \geq 92\%$ và hội tụ ≤ 40 vòng; cùng với bộ phân tích mối quan hệ Jensen-Shannon Divergence (JSD) và độ chính xác (Accuracy) trên dữ liệu CSI.


MỤC TIÊU (Viết trong vòng 3 mục tiêu)

Mục tiêu 1: Xây dựng bộ dataset WiFi CSI đa môi trường từ 3–5 ESP32-S3, đảm bảo mức độ Non-IID giữa các cặp node đạt $JSD \geq 0.15$ (ngưỡng thực nghiệm được lựa chọn để đại diện cho mức Non-IID trung bình đến cao trong nghiên cứu này), và xác lập mối quan hệ định lượng giữa mức JSD và sự suy giảm Accuracy.

Mục tiêu 2: Thiết kế và đánh giá thuật toán FedJPA — kết hợp JSD-based weighted aggregation (overhead ≤ 2 KB/round) và layer-split personalization tương thích ESP32-S3 — đạt Accuracy $\geq 92\%$, F1-Score $\geq 88\%$, hội tụ trong ≤ 40 vòng, và fairness $\leq 5\%$ độ lệch giữa các node, vượt trội so với FedAvg, FedProx và FedNova trong cùng điều kiện Non-IID.

Mục tiêu 3: Triển khai và kiểm chứng FedJPA trên ESP32-S3 thực tế (RAM ≤ 520 KB, Flash ≤ 4 MB) sử dụng TFLite Micro cho inference và C-language cho local gradient update, đảm bảo toàn bộ pipeline từ thu thập CSI đến suy luận chạy trên thiết bị mà không cần kết nối liên tục với server.

NỘI DUNG VÀ PHƯƠNG PHÁP



Hình 1: Kiến trúc tổng quát FedJPA

1. Xây dựng hệ thống thu thập dữ liệu CSI trên ESP32

Hệ thống thu thập dữ liệu được xây dựng trên 3–5 thiết bị ESP32-S3 sử dụng firmware tùy chỉnh trích xuất CSI từ gói beacon WiFi 802.11n. Mỗi cặp phát–thu được đặt tại một môi trường vật lý riêng biệt: phòng nhỏ ($\sim 15 \text{ m}^2$), phòng lớn ($\sim 30 \text{ m}^2$) và hành lang ($\sim 50 \text{ m}^2$). Dữ liệu được gán nhãn dựa trên kịch bản thu thập được thiết kế trước (có/không có người). Mỗi node thu tối thiểu 2.000 mẫu mỗi lớp trên ít nhất 3 phiên thu thập khác nhau để đảm bảo tính ổn định theo thời gian và đại diện cho biến động môi trường thực tế.

2. Tiền xử lý và trích xuất đặc trưng CSI

Dữ liệu CSI thô gồm amplitude và phase trên 52–64 subcarrier được tiền xử lý theo ba bước: (i) lọc nhiễu bằng bộ lọc Hampel kết hợp moving average; (ii) chuẩn hóa biên độ theo từng subcarrier; (iii) lựa chọn subcarrier có variance cao nhất để giảm chiều. Đặc trưng thống kê được trích xuất gồm mean, standard deviation, skewness, kurtosis của biên độ và đặc trưng phổ từ STFT. Từ tập đặc trưng này, histogram subcarrier-level amplitude (16–32 bin/subcarrier, nén $\sim 2 \text{ KB}$) cũng được tính để phục vụ định lượng JSD.

3. Định lượng mức độ Non-IID bằng Jensen-Shannon Divergence

Mức độ không đồng nhất giữa các node được định lượng qua Jensen-Shannon Divergence tính trên histogram biên độ CSI theo subcarrier — đây là đặc trưng đặc thù của môi trường vật lý, nhẹ về tính toán (không cần forward pass) và phù hợp với ràng buộc ESP32. Ma trận JSD toàn cặp ($n \times n$) cho thấy cấu trúc Non-IID giữa các vị trí được triển khai. Thực nghiệm kiểm chứng giả thuyết: JSD đồng biến với mức suy giảm Accuracy của FedAvg, qua đó xác nhận tính hợp lệ của JSD làm proxy cho mức độ client drift.

4. Thuật toán FedJPA

FedJPA kết hợp 2 cơ chế bổ sung:

Cơ Chế 1 - JSD-Based Weighted Aggregation: Mỗi client C_i gửi lên server gradient của shared layers $\Delta\theta_i^s$ cùng histogram phân phối h_i ($\leq 2KB$). Server tính độ tương đồng sim_i và trọng số tổng hợp w_i :

$$sim_i = 1 - \frac{1}{n-1} \sum_{j \neq i} JSD(h_i, h_j)$$

$$w_i = \frac{\left(\frac{n_i}{N}\right) \cdot sim_i}{\sum_{j=1}^K \left(\frac{n_j}{N} \cdot sim_j\right)}$$

Trong đó:

- w_i : trọng số của client i trong quá trình tổng hợp.
- n_i : số mẫu dữ liệu tại client i .
- N : tổng số mẫu của tất cả client.
- sim_i : độ tương đồng của client i với mô hình toàn cục.
- K : số lượng client tham gia vòng huấn luyện.

Cơ chế 2 - Layer-split personalization: Model được chia thành shared layers θ^s (feature extractor, chiếm $\sim 80\%$ tham số) và personal layer θ_i^p (classifier head, $\sim 20\%$ tham số). Chỉ $\Delta\theta_i^s$ được gửi lên server để tổng hợp; θ_i^p giữ tại ESP32 và tiếp tục cập nhật local. Cấu trúc này giúp mô hình toàn cục học đặc trưng CSI phổ quát trong khi mỗi node thích nghi với đặc tính môi trường riêng.

5. Triển khai và đánh giá thực nghiệm

Năm thuật toán được so sánh trong cùng điều kiện thực nghiệm: Local Training (lower bound), FedAvg [1], FedProx [2], FedNova [3] và FedJPA đề xuất. Pipeline được hiện thực bằng Python/PyTorch + Flower framework cho phía server; phía thiết

bị sử dụng TFLite Micro cho inference và C-language cho local gradient update của shared layers. Đánh giá sử dụng leave-one-environment-out cross-validation — mỗi fold giữ lại một môi trường hoàn toàn mới làm tập test, đánh giá đúng khả năng generalization. Các chỉ tiêu gồm Accuracy, F1-Score, tốc độ hội tụ, fairness (độ lệch chuẩn Accuracy giữa các node) và communication overhead (byte/round).

KẾT QUẢ MONG ĐỢI

- Hệ thống thu thập và xử lý dữ liệu CSI trên nền tảng ESP32 phục vụ bài toán phát hiện sự hiện diện của con người.
- Thuật toán FedJPA mang lại cải thiện toàn diện so với các phương pháp Federated Learning truyền thống trong điều kiện dữ liệu Non-IID trên CSI.
- Về hiệu năng phân loại, FedJPA dự kiến đạt $\text{Accuracy} \geq 92\%$ và $\text{F1-Score} \geq 88\%$ trên tập dữ liệu đa môi trường, vượt trội so với Local Training ($\sim 75\text{--}80\%$), FedAvg ($\sim 82\text{--}87\%$) và FedProx ($\sim 84\text{--}88\%$) trong cùng điều kiện thực nghiệm.
- Về tốc độ hội tụ, FedJPA dự kiến đạt ngưỡng 90% Accuracy trong ≤ 40 vòng giao tiếp, nhanh hơn FedAvg (55–70 vòng) và FedProx (45–60 vòng), nhờ cơ chế tổng hợp trọng số thích nghi theo mức độ tương đồng phân phối.
- Về tính công bằng giữa các client (fairness), độ lệch hiệu năng giữa các node dự kiến giảm xuống $\leq 5\%$, thấp hơn đáng kể so với FedAvg (10–15%) và FedProx (7–12%), cho thấy khả năng giảm client drift trong môi trường Non-IID.
- Về chi phí hệ thống, mô hình dự kiến vẫn đảm bảo khả năng triển khai trên ESP32-S3 với giới hạn tài nguyên (RAM ~ 520 KB, Flash ~ 4 MB), đồng thời duy trì mức truyền thông tương đương FedAvg do không tăng kích thước gradient trao đổi.

TÀI LIỆU THAM KHẢO (Định dạng DBLP)

[1] H. Brendan McMahan, Eedair Moore, Daniel Ramage, Seth Hampson, Blaise Agüera y Arcas: Communication-Efficient Learning of Deep Networks from

Decentralized Data. AISTATS, PMLR 54: 1273-1282, 2017.

[2] Tian Li, Anit Kumar Sahu, Manzil Zaheer, Maziar Sanjabi, Ameet Talwalkar, Virginia Smith: Federated Optimization in Heterogeneous Networks. MLSys, 2020.

[3] Jianyu Wang, Qinghua Liu, Hao Liang, Gauri Joshi, H. Vincent Poor: Tackling the Objective Inconsistency Problem in Heterogeneous Federated Optimization. NeurIPS: 7611-7623, 2020.

[4] Jingtao Guo, Yuyi Mao, Ivan Wang-Hei Ho: FedAPA: Federated Learning with Adaptive Prototype Aggregation Toward Heterogeneous Wi-Fi CSI-based Crowd Counting. CoRR abs/2511.21048, 2025.