



UIT

TRƯỜNG ĐẠI HỌC
CÔNG NGHỆ THÔNG TIN

MỘT PHƯƠNG PHÁP HỌC LIÊN KẾT THÍCH NGHI DỰA TRÊN JSD VÀ CÁ NHÂN HÓA MÔ HÌNH CHO DỮ LIỆU WIFI CSI KHÔNG ĐỒNG NHẤT

A JSD-GUIDED PERSONALIZED FEDERATED LEARNING APPROACH FOR NON-IID WIFI CSI DATA

Nguyễn Hoàng Nam
250106023


✉ 250106023@grad.uit.edu.vn

University of Information Technology,
Ho Chi Minh City, Vietnam

TÓM TẮT

Nhận diện sự hiện diện của con người dựa trên thông tin trạng thái kênh WiFi (CSI) là một hướng nghiên cứu tiềm năng trong các hệ thống nhà thông minh, quản lý năng lượng và giám sát an ninh nhờ khả năng bảo vệ quyền riêng tư. Khi triển khai trên nhiều thiết bị ESP32 tại các môi trường khác nhau, Federated Learning (FL) cho phép huấn luyện mô hình chung mà không cần tập trung dữ liệu CSI về máy chủ. Tuy nhiên, sự khác biệt về môi trường làm cho dữ liệu CSI giữa các thiết bị có phân phối không đồng nhất (Non-IID), gây client drift và làm giảm hiệu quả các thuật toán FL truyền thống. Để giải quyết vấn đề này, FedJPA, kết hợp cơ chế tổng hợp có trọng số dựa trên Jensen-Shannon Divergence (JSD) và cơ chế cá nhân hóa mô hình (layer-split personalization). FedJPA được đánh giá trên 3-5 thiết bị ESP32-S3 tại nhiều môi trường thực tế. Kết quả kỳ vọng: Accuracy $\geq 92\%$, F1-Score $\geq 88\%$, hội tụ trong ≤ 40 vòng và vượt trội so với các phương pháp FL cơ bản trong điều kiện Non-IID thực tế.

HÌNH 1. KIẾN TRÚC TỔNG QUÁT FEDJPA



1. GIỚI THIỆU

Nhận diện sự hiện diện của con người bằng WiFi CSI có ưu điểm bảo mật cao hơn so với camera. Tuy nhiên, dữ liệu CSI giữa các thiết bị có phân phối khác nhau (Non-IID) do môi trường triển khai, làm giảm hiệu quả các thuật toán FL truyền thống như FedAvg.

Khoảng trống nghiên cứu:

- Các phương pháp FL giải quyết Non-IID chủ yếu thử nghiệm trên benchmark ảnh nhân tạo.
- Trong WiFi CSI, Non-IID xuất hiện tự nhiên từ môi trường thực tế nhưng chưa được định lượng hệ thống.
- Nghiên cứu FL trên nền tảng nhúng hạn chế tài nguyên (ESP32) còn rất hạn chế.

Input - Output của nghiên cứu

Input	Output
- Dữ liệu WiFi CSI từ 3-5 ESP32 - Nhân nhĩ phân: có người / không có người - Số lượng mẫu và phân phối đặc trưng tại mỗi node	- Mô hình: shared layers θ_s^o và personal layers θ_i^p. - Accuracy $\geq 92\%$, hội tụ ≤ 40 vòng - Phân tích mối quan hệ JSD và Accuracy trên dữ liệu CSI

2. MỤC TIÊU


- Mục tiêu 1:** Xây dựng dataset WiFi CSI đa môi trường từ 3-5 ESP32-S3, đảm bảo mức độ Non-IID giữa các cặp node đạt $JSD \geq 0.15$ và xác lập mối quan hệ định lượng giữa mức JSD và sự suy giảm Accuracy.
- Mục tiêu 2:** Thiết kế và đánh giá thuật toán FedJPA — kết hợp JSD-based weighted aggregation (overhead ≤ 2 KB/round) và layer-split personalization tương thích ESP32-S3 — đạt Accuracy $\geq 92\%$, F1-Score $\geq 88\%$, hội tụ trong ≤ 40 vòng, và fairness $\leq 5\%$ độ lệch giữa các node, vượt trội so với FedAvg, FedProx và FedNova trong cùng điều kiện Non-IID.
- Mục tiêu 3:** Triển khai và kiểm chứng FedJPA trên ESP32-S3 thực tế (RAM ≤ 520 KB, Flash ≤ 4 MB) sử dụng TFLite Micro cho inference và C-language cho local gradient update, đảm bảo toàn bộ pipeline từ thu thập CSI đến suy luận chạy trên thiết bị mà không cần kết nối liên tục với server.

3. DỮ LIỆU VÀ TIỀN XỬ LÝ

Thu thập dữ liệu CSI

- 3-5 ESP32-S3, thu CSI từ beacon 802.11n
- Môi trường: phòng nhỏ (~ 15 m²), phòng lớn (~ 30 m²), hành lang (~ 50 m²)
- Mỗi node: tối thiểu 2.000 mẫu mỗi lớp, ≥ 3 phiên thu

Tiền xử lý



Đặc trưng trích xuất

- Thống kê biến độ: mean, std, skewness, kurtosis
- Đặc trưng phổ: STFT
- Histogram biến độ theo subcarrier (16-32 bin/subcarrier, nén ~ 2 KB) $\rightarrow$ dùng để tính JSD

4. THUẬT TOÁN FEDJPA

FedJPA kết hợp 2 cơ chế bổ sung:

Cơ chế 1 - JSD-Based Weighted Aggregation

Mỗi client C_i gửi lên server gradient của shared layers $\Delta\theta_i^s$ cùng histogram phân phối h_i (≤ 2 KB). Server tính độ tương đồng sim_i ; và trọng số tổng hợp w_i .

$$sim_i = 1 - \frac{1}{n-1} \sum_{j \neq i} JSD(h_i, h_j)$$

$$w_i = \frac{\left(\frac{n_i}{N}\right) \cdot sim_i}{\sum_{j=1}^K \left(\frac{n_j}{N}\right) \cdot sim_j}$$

Trong đó:

- w_i : trọng số của client i trong quá trình tổng hợp.
- n_i : số mẫu dữ liệu tại client i .
- N : tổng số mẫu của tất cả client.
- sim_i : độ tương đồng của client i với mô hình toàn cục.
- K : số lượng client tham gia vòng huấn luyện.


Cơ chế 2 - Layer-split Personalization

- Shared layers (θ_s^o): tổng hợp toàn cục bằng trọng số w_i .
- Personal layers (θ_i^p): giữ lại và cập nhật cục bộ trên từng client.

Thuật toán tổng quát

- Client i : tính $\Delta\theta_i^s$ và histogram $h_i \rightarrow$ gửi lên server
- Server: tính $sim_i, w_i \rightarrow$ tổng hợp θ^s
- Server: broadcast θ^s cho các client
- Client i : cập nhật θ_i^p cục bộ
- Lặp lại đến khi hội tụ

5. KẾT QUẢ DỰ KIẾN

Accuracy
 $\geq 92\%$ F1-Score
 $\geq 88\%$ Hội tụ
 ≤ 40 vòngFairness
 $\leq 5\%$

FedJPA đạt hiệu năng tốt hơn FedAvg, FedProx và FedNova trong điều kiện dữ liệu CSI Non-IID.

6. NỀN TẢNG TRIỂN KHAI

Phần cứng

Phần mềm

7. TÀI LIỆU THAM KHẢO

- [1] B. McMahan et al., "Communication-Efficient Learning of Deep Networks from Decentralized Data,"