

MỘT PHƯƠNG PHÁP HỌC LIÊN KẾT THÍCH NGHI DỰA TRÊN JSD VÀ CÁ NHÂN HÓA MÔ HÌNH CHO DỮ LIỆU WIFI CSI KHÔNG ĐỒNG NHẤT

HVTH: Nguyễn Hoàng Nam - 250106023
GVHD: PGS. TS. Lê Đình Duy

Tóm tắt

- Họ và tên: Nguyễn Hoàng Nam
- Lớp: CS2205.JAN2026
- Link Github của nhóm: <https://github.com/namnh-tt/CS2205.JAN2026>
- Link YouTube video: <https://youtu.be/iOvACe4b7a0>



Giới thiệu

- **Bối cảnh:** Nhận diện người qua WiFi CSI là xu hướng bảo mật quyền riêng tư thay thế camera.
- **Giải pháp:** Federated Learning (FL) giúp huấn luyện mô hình phân tán trên thiết bị nhúng (ESP32).
- **Thách thức:** Môi trường thực tế khác nhau gây nhiễu và sai lệch dữ liệu giữa các thiết bị (Non-IID).
- **Hạn chế hiện tại:** Các thuật toán FL truyền thống (FedAvg, FedProx) giảm độ chính xác; các phương pháp mới (FedAPA) quá nặng cho thiết bị nhúng.
- **Đề xuất:** Thuật toán FedJPA – Kết hợp định lượng JSD và cá nhân hóa mô hình

Mục tiêu

- **Mục tiêu 1:** Xây dựng Dataset WiFi CSI đa môi trường (3–5 node ESP32-S3); xác lập mối quan hệ giữa độ lệch phân phối (JSD) và độ chính xác (Accuracy).
- **Mục tiêu 2:** Thiết kế thuật toán FedJPA đạt Accuracy $\geq 92\%$, F1-Score $\geq 88\%$, hội tụ nhanh (≤ 40 vòng).
- **Mục tiêu 3:** Triển khai thực tế trên phần cứng ESP32-S3 (TFLite Micro/C); tối ưu tài nguyên (RAM $< 520\text{KB}$) và khả năng xử lý Offline.

Nội dung và Phương pháp

- Thu thập dữ liệu: Triển khai 3–5 node ESP32-S3 tại các phòng có diện tích khác nhau ($15\text{m}^2 - 50\text{m}^2$).
- Tiền xử lý: Lọc nhiễu Hampel, chuẩn hóa biên độ và trích xuất đặc trưng phổ (STFT).
- Định lượng Non-IID: Sử dụng Jensen-Shannon Divergence (JSD) trên histogram biên độ để đo độ tương đồng giữa các node (chi phí tính toán thấp).

Nội dung và Phương pháp

- Cơ chế FedJPA:
 - Tổng hợp trọng số: Ưu tiên các client có độ tương đồng cao với mô hình chung.
 - Cá nhân hóa: Tách lớp Shared Layers (80% – tổng hợp toàn cục) và Personalized Layer (20% – giữ tại thiết bị).

Kết quả dự kiến

- **Hiệu năng vượt trội:** Accuracy $\geq 92\%$, vượt xa các phương pháp truyền thống (FedAvg, FedProx).
- **Tốc độ hội tụ:** Đạt ngưỡng ổn định chỉ sau ≤ 40 vòng giao tiếp (nhanh hơn 30–40% so với FedAvg).
- **Tính công bằng (Fairness):** Độ lệch hiệu năng giữa các môi trường $\leq 5\%$ (giảm thiểu client drift).
- **Khả năng triển khai:** Vận hành mượt mà trên ESP32-S3; chi phí truyền thông thấp (overhead $\leq 2\text{KB}$).

Tài liệu tham khảo

- [1] H. Brendan McMahan, Eedair Moore, Daniel Ramage, Seth Hampson, Blaise Agüera y Arcas: Communication-Efficient Learning of Deep Networks from Decentralized Data. AISTATS, PMLR 54: 1273-1282, 2017.
- [2] Tian Li, Anit Kumar Sahu, Manzil Zaheer, Maziar Sanjabi, Ameet Talwalkar, Virginia Smith: Federated Optimization in Heterogeneous Networks. MLSys, 2020.
- [3] Jianyu Wang, Qinghua Liu, Hao Liang, Gauri Joshi, H. Vincent Poor: Tackling the Objective Inconsistency Problem in Heterogeneous Federated Optimization. NeurIPS: 7611-7623, 2020.
- [4] Jingtao Guo, Yuyi Mao, Ivan Wang-Hei Ho: FedAPA: Federated Learning with Adaptive Prototype Aggregation Toward Heterogeneous Wi-Fi CSI-based Crowd Counting. CoRR abs/2511.21048, 2025.